





TRABALHO PRÁTICO - 1

**Alunos: Eduardo Morais Silva Martins
e Maurílio Rittershausen Novaes**






PORTO SEGURO'S SAFE DRIVER PREDICTION


Este problema do Kaggle tem como objetivo prever a probabilidade de um motorista acionar o seguro de automóvel no próximo ano.

Atualmente, erros nessas previsões fazem com que:

- bons motoristas paguem mais caro do que deveriam
- motoristas de maior risco paguem menos


A Porto Seguro, uma das maiores seguradoras do Brasil, busca melhorar esses modelos utilizando técnicas de Machine Learning mais avançadas.





SOBRE OS DADOS DO PROBLEMA



- Possui 58 atributos com nomes genéricos, dificultando a análise visual de relevância
 - Presença de muitos valores nulos, porém sem grande impacto após tratamento
 - Ausência de ruídos significativos nos dados
 - Não há tendências ou padrões claros identificáveis diretamente
 - Dataset aparentemente já foi previamente tratado pela organização
- 
- 

MÉTRICA DE AVALIAÇÃO - GINI NORMALIZADO

Coeficiente Gini:

$$G = \frac{1}{n} \left(\frac{\sum_{i=1}^n S_i}{\sum_{i=1}^n y_i} - \frac{n+1}{2} \right)$$

n : número total de amostras

y_i : valor real (target) da amostra i

$S_i = \sum_{j=1}^n y_j$: soma acumulada dos valores reais

$\sum_{i=1}^n y_i$: total de positivos do data set

MÉTRICA DE AVALIAÇÃO - GINI NORMALIZADO

COEFICIENTE GINI NORMALIZADO:


$$G_{norm} = \frac{G(y, \hat{y}^p)}{G(y, y)}$$

$G(y, \hat{y}^p)$: Gini calculado usando as previsões do modelo

$G(y, y)$: Gini ideal

$\hat{y}^p$: valores preditos

y : valores reais





MÉTRICA DE AVALIAÇÃO - GINI NORMALIZADO

Para a resolução do problema, foi utilizado o Gini Normalizado na forma equivalente


$$2 \times AUC - 1$$


Essa escolha foi feita devido à facilidade de implementação, uma vez que o valor da AUC (Area Under the ROC Curve) já é diretamente fornecido pelas ferramentas de validação cruzada do scikit-learn.






BASE LINE - XGBOOST


- O algoritmo base escolhido para a solução foi o XGBoost, devido ao seu alto desempenho em problemas de classificação e ampla utilização em competições de Machine Learning.
 - Mesmo sem a aplicação de técnicas de otimização de hiperparâmetros, o modelo já apresentou resultados consistentes.
 - Gini Normalizado (Local): 0.23210
 - Gini Normalizado (Kaggle): 0.22902
- 
- 



OTIMIZAÇÃO - XGBoost





- Para otimizar o modelo XGBoost, foi utilizado o Optuna, uma biblioteca de otimização de hiperparâmetros baseada em busca inteligente (Bayesian Optimization).
 - Além disso, foi aplicada a técnica de seleção de atributos com BorutaPy, que identifica as variáveis mais relevantes para o modelo.
 - Gini Normalizado (Local): 0.28753
 - Gini Normalizado (Kaggle): 0.27909
- 
- 



BASE - LIGHTGBM




- Como segunda abordagem, foi utilizado o LightGBM. Sua escolha teve como objetivo complementar o XGBoost, já que, apesar de semelhantes, os modelos possuem diferenças na forma de aprendizado.
 - Enquanto o XGBoost cresce árvores de forma mais conservadora, o LightGBM utiliza uma abordagem mais agressiva, permitindo capturar padrões diferentes nos dados.
 - Gini Normalizado (Local): 0.27580
 - Gini Normalizado (Kaggle): 0.27218
- 
- 




OTIMIZAÇÃO - LIGHTGBM



- Para a otimização do modelo LightGBM, foi utilizado apenas o Optuna, responsável pela busca eficiente dos melhores hiperparâmetros. Diferentemente do XGBoost, a seleção de atributos não apresentou ganhos.
 - O crescimento leaf-wise faz o LightGBM aproveitar melhor múltiplos atributos, o que explica por que a seleção de features pode não trazer ganhos ou até prejudicar.
 - Gini Normalizado (Local): 0.28429
 - Gini Normalizado (Kaggle): 0.28061
- 
- 


BASE - GAUSSIANNB

- Como terceira e última abordagem, foi utilizado o Gaussian Naive Bayes (GaussianNB), com o objetivo de complementar os modelos anteriores e explorar regiões do espaço de dados que não foram bem capturadas.
- Diferentemente do XGBoost e do LightGBM, o GaussianNB é um modelo probabilístico e não baseado em árvores, o que permite introduzir uma nova perspectiva de aprendizado.
- Gini Normalizado (Local): 0.23240
- Gini Normalizado (Kaggle): 0.22769





OTIMIZAÇÃO - GAUSSIANNB



- Para a otimização do modelo GaussianNB, foi utilizado o Optuna para ajuste de hiperparâmetros e o BorutaPy para seleção de atributos. No entanto, como o GaussianNB não é compatível com o Boruta, foi necessário utilizar um modelo auxiliar, sendo escolhido o Random Forest.
 - Isso ocorre porque o Boruta depende de medidas de importância das variáveis, fornecidas por modelos baseados em árvores.
 - Gini Normalizado (Local): 0.23683
 - Gini Normalizado (Kaggle): 0.23182
- 
- 


META LEARNING - EMPILHAMENTO







META LEARNING - EMPILHAMENTO



- Utilização da técnica de stacking (empilhamento) para combinar múltiplos modelos
 - Geração de previsões out-of-fold (OOF)
 - Treinamento de um meta-modelo para combinar as previsões
 - Otimização dos hiperparâmetros com Optuna
 - Gini Normalizado (Local): 0.28685
 - Gini Normalizado (Kaggle): 0.28141
- 
- 


META LEARNING - EMPILHAMENTO + ENRIQUECIMENTO





META LEARNING - EMPILHAMENTO + ENRIQUECIMENTO






- Concatenação das features originais + previsões dos modelos
 - Aplicação de normalização (StandardScaler) para padronização das variáveis
 - Treinamento de um meta-modelo baseado em LightGBM
 - Meta-modelo capaz de capturar relações não lineares mais complexas
 - Gini Normalizado (Local): 0.28425
 - Gini Normalizado (Kaggle): 0.28089
- 
- 

COMPARATIVO ENTRE CLASSIFICADORES

	Local (sem otm)	Kaggle (sem otm)	Local (com otm)	Kaggle (com otm)
XGBoost	0.23210	0.22902	0.28753	0.27909
LightGBM	0.27580	0.27218	0.28429	0.28061
GaussianNB	0.23240	0.22769	0.23683	0.23182
Empilhamento	-	-	0.28685	0.28141
Empilhamento + Enriquecimento	-	-	0.28425	0.28089

A light gray grid pattern covers the entire background of the slide.

OBRIGADO!

A cluster of dark blue dots in the top left corner, arranged in a grid that tapers to the right.Large, overlapping blue circular and semi-circular shapes in the top right corner, some with diagonal hatching.Overlapping blue circular and semi-circular shapes in the bottom left corner, some with diagonal hatching.A cluster of dark blue dots in the bottom right corner, arranged in a grid that tapers to the left.